

INICIAÇÃO CIENTÍFICA - IMT

# DESENVOLVIMENTO DE ALGORITMOS DE PROCESSAMENTO DE IMAGEM PARA IDENTIFICAÇÃO DE PRAGAS EM LAVOURAS DE TRIGO

**Feito por:** Otto Camargo Kuchkarian  
Wânderson de Oliveira Assis  
Fernando de Almeida Martins  
Alessandra Dutra Coelho

# Estrutura da Apresentação

Tópicos



Introdução

Problema

Projeto

Resultados

Conclusão

# Introdução

## Importância da agricultura

[Home](#) > [EXAME Agro](#)

**Agro brasileiro sustenta superávits da balança comercial brasileira desde 1989, mostra estudo**

[Home](#) > [EXAME Agro](#)

**Agricultura de precisão: o que é e por que tem sido tão importante para a produção de alimentos**

[Home](#) > [EXAME Agro](#)

**Exportações do agro paulista crescem 8,9% no primeiro semestre e seguram balança comercial de SP**





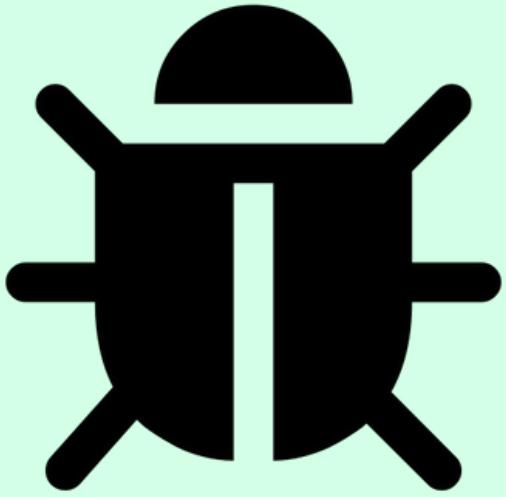
# Problema

## Ameaça das Pragas

- Durante a década de 1970, houve um aumento significativo da população de pulgões , com severas infestações nas lavouras
- As pragas podem afetar o trigo de várias formas, desde o desenvolvimento da lavoura até a fase de armazenamento da safra
- O ataque de pragas pode ocorrer em diferentes fases do desenvolvimento da cultura, afetando todas as partes da planta

# Projeto

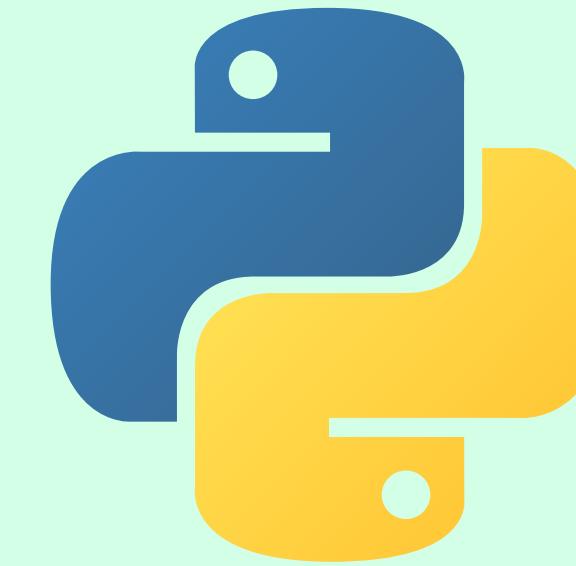
## Etapas do projeto



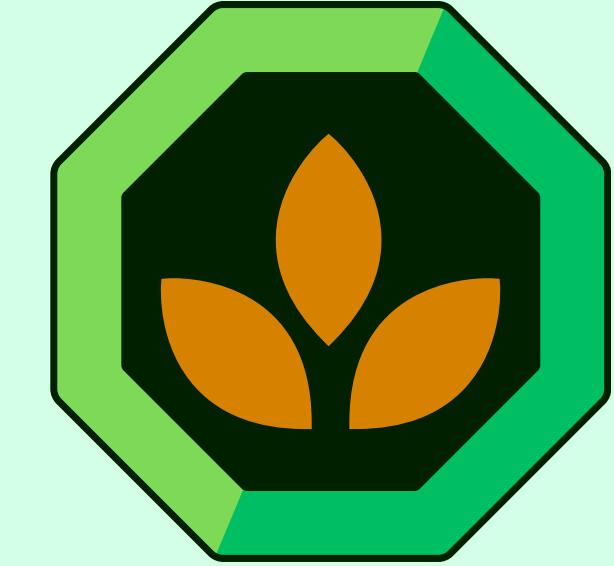
**Seleção das Pragas**



**Modelo de  
Reconhecimento**



**Criação do Sistema**

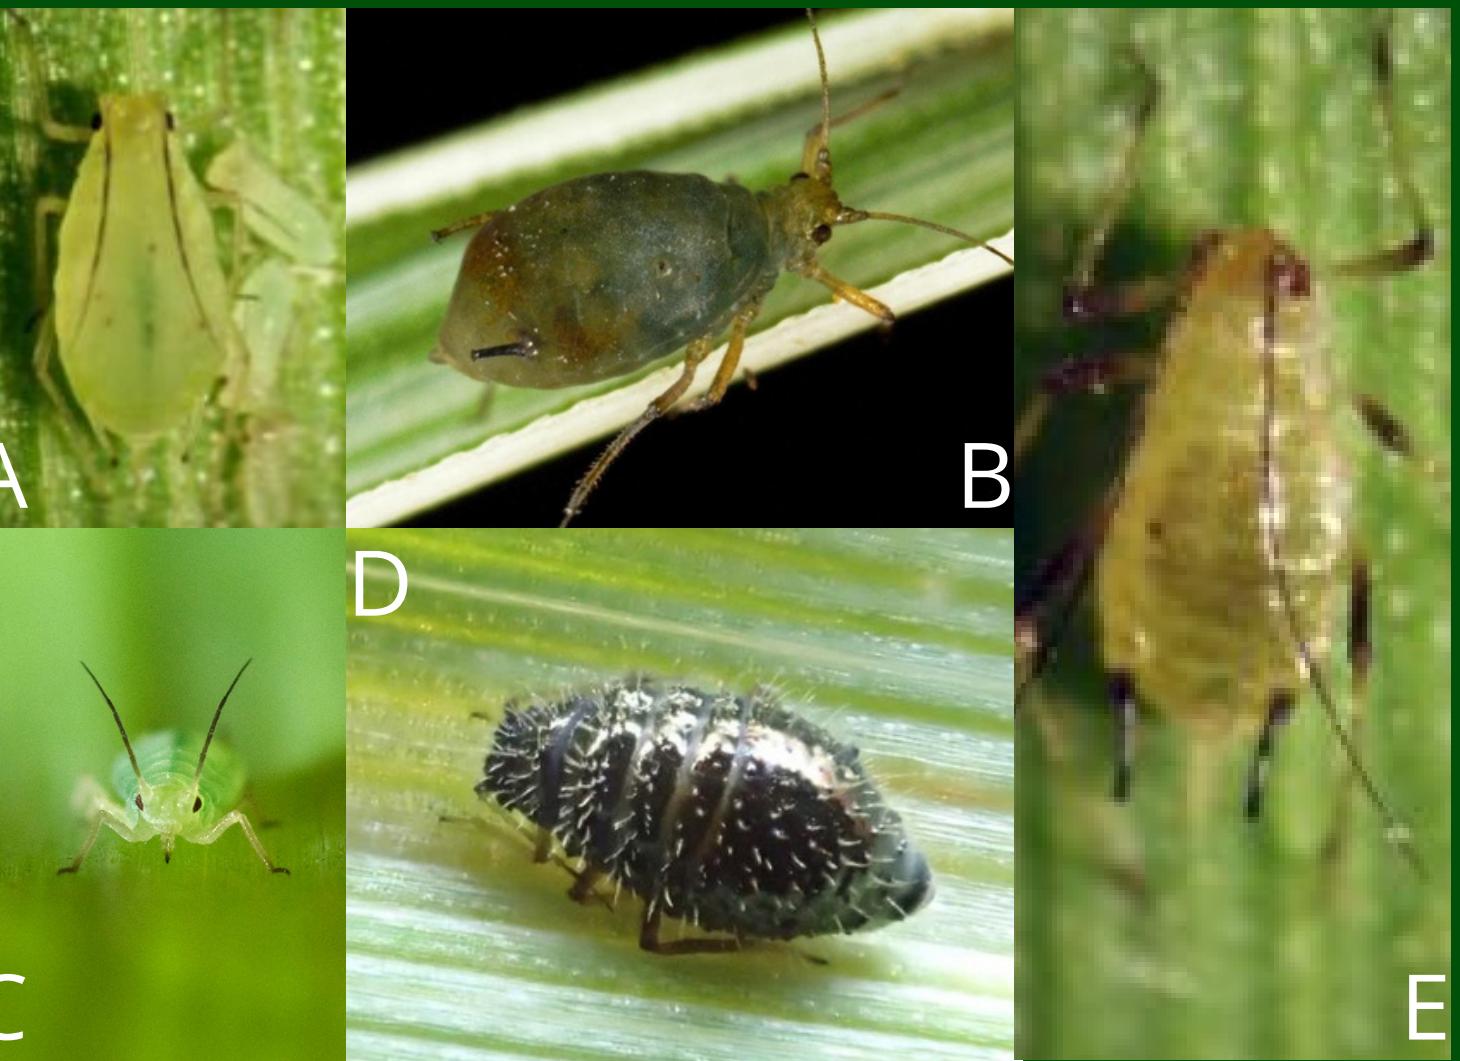


**Compartilhamento  
de Informações**

# Seleção de Pragas

**Pragas mais comuns nas lavouras de trigo**

- A. Pulgão-verde-pálido (*Metopolophium dirhodum*)
- B. Piolho-da-cerejeira-brava (*Rhopalosiphum padi*)
- C. Pulgão verde dos cereais (*Schizaphis graminum*)
- D. Pulgão preto dos cereais (*Sipha maydis*)
- E. Pulgão-da-espiga (*Sitobion avenae*)



# Roboflow

## Plataforma de Visão Computacional

- **Plataforma para Visão Computacional:**
  - Permite construir, treinar e implementar modelos de visão computacional rapidamente
- **Treinamento com Redes Neurais e Deep Learning:**
  - Utiliza Redes Neurais Artificiais para treinar modelos de detecção de objetos
- **Suporte Multiplataforma:**
  - Funciona com Python, JavaScript e várias bibliotecas de *machine learning* (TensorFlow, PyTorch, etc.)
- **Interface Gráfica Simples**
  - UI intuitiva para gerenciamento de datasets, criação de pipelines de treinamento e acompanhamento de métricas

# Modelos de Reconhecimento

## Modelo 1 Vs. Modelo 2

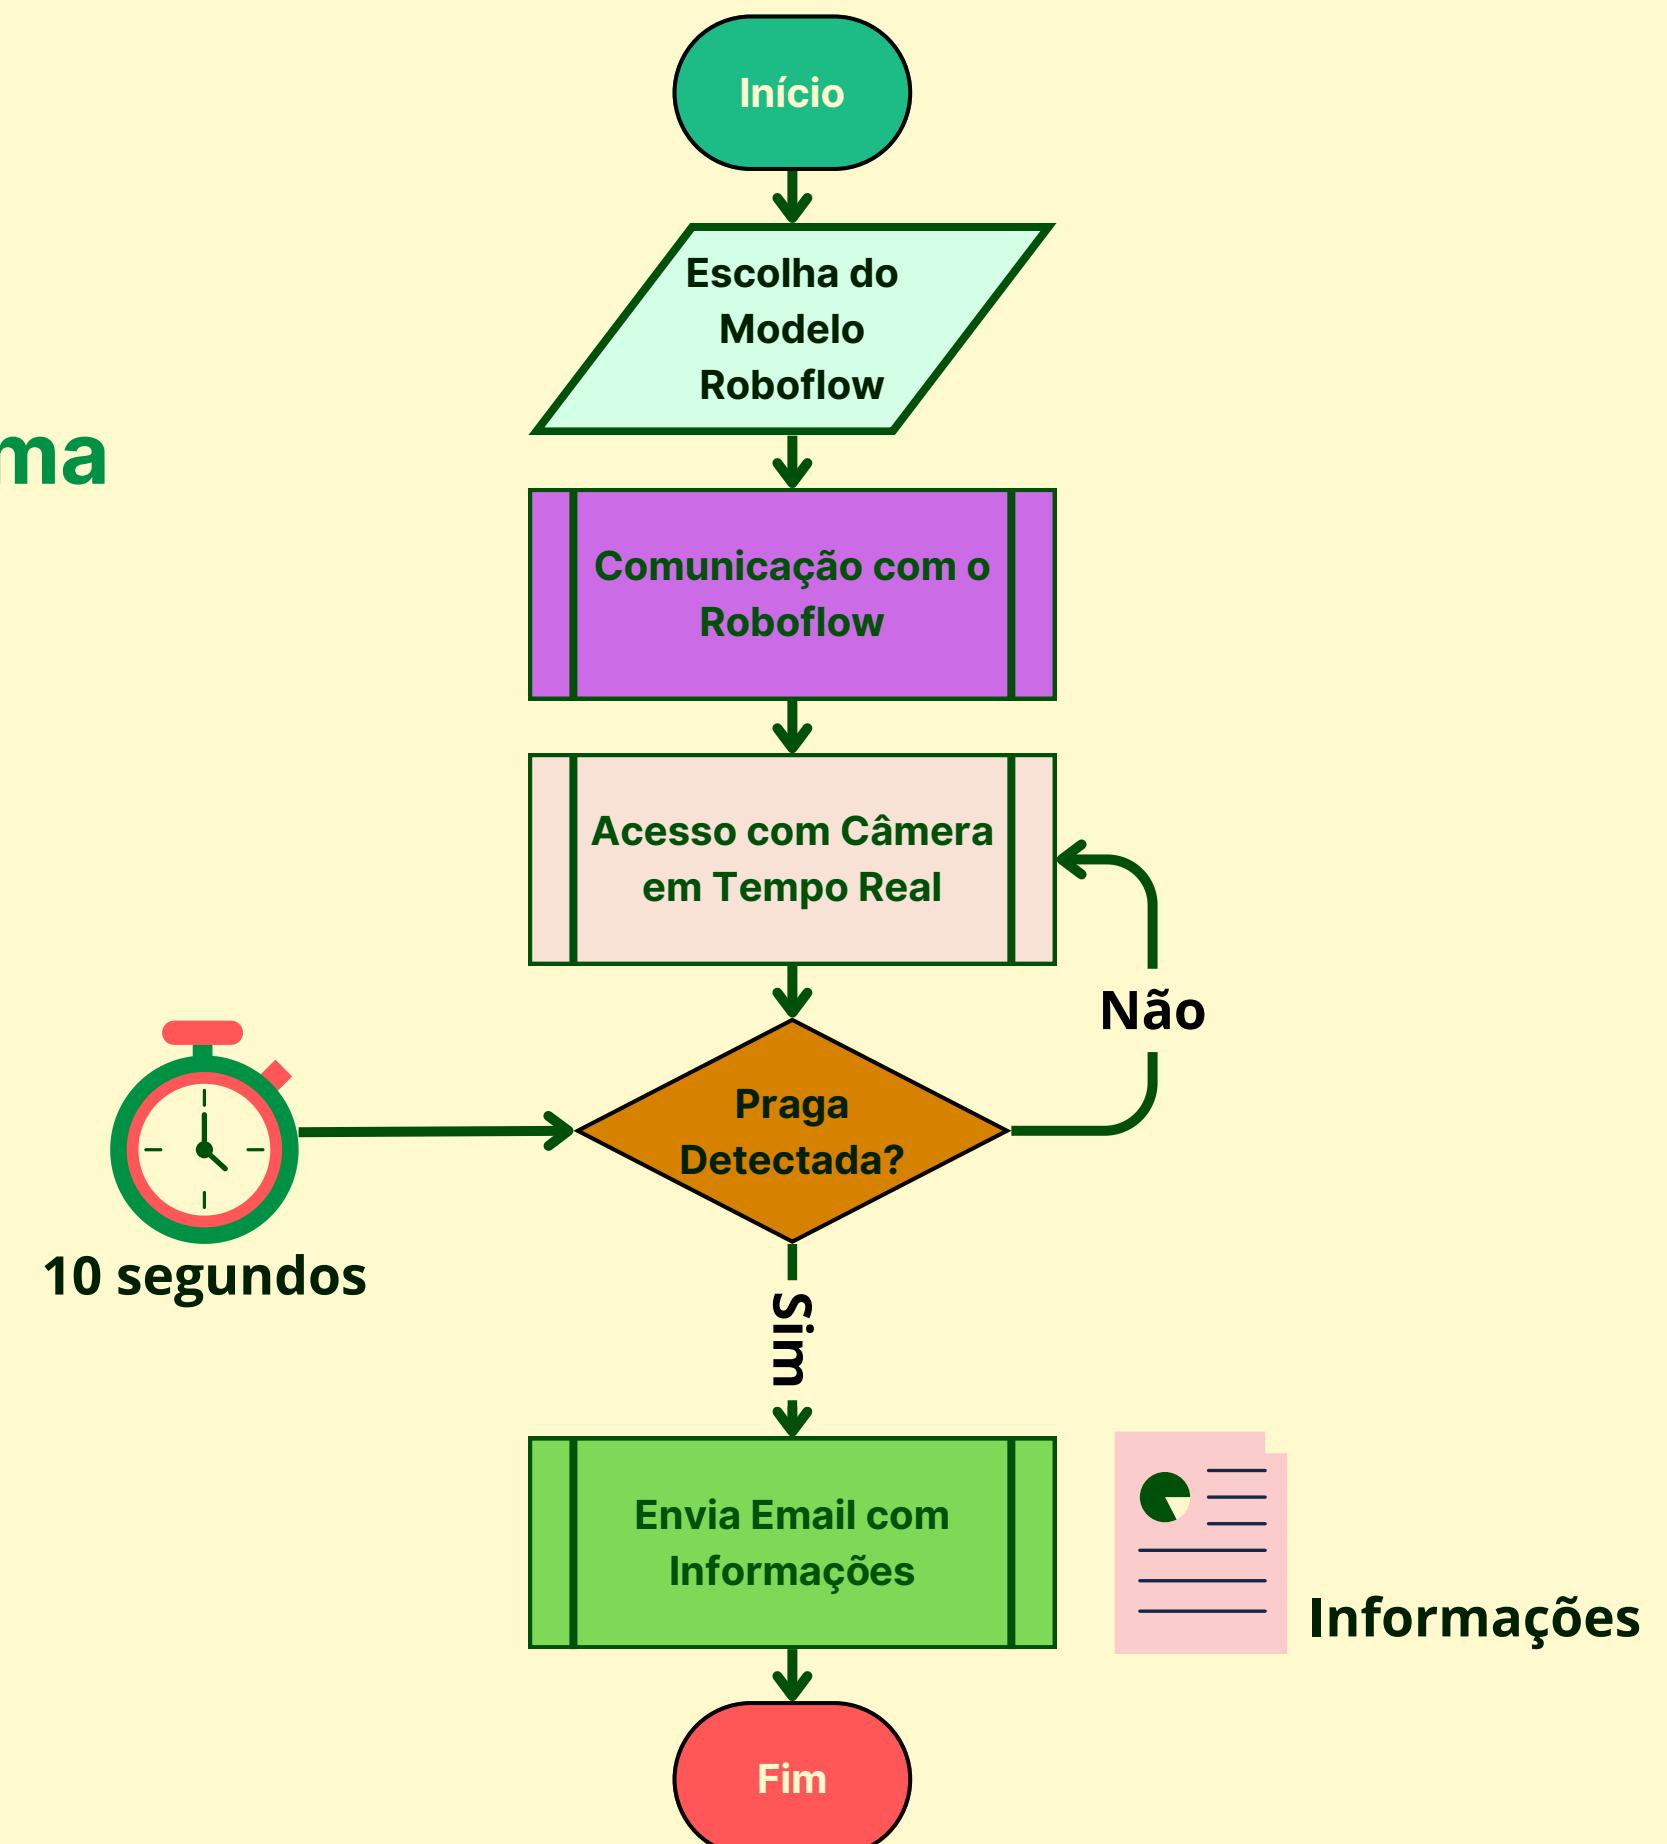
### Comparação dos Modelos

Modelos	Versão 1	Versão 2 (sem Pulgão verde dos cereais)
precisão	84.8%	93.1%
mAP	80.3%	91.1%
recall	75.4%	84.5%

- **precisão:** frequência com que as previsões do seu modelo estão corretas;
- **mAP:** precisão média de detecções corretas em modelos de visão computacional;
- **recall:** proporção de objetos corretamente detectados em relação ao total de objetos reais.

# Criação do Sistema

## Fluxograma do Sistema



# Compartilhamento de Informações e-mail encaminhado ao usuário

Lista das pragas do modelo e a quantidade delas identificadas



Informações do dia da identificação

Imagen da identificação

# Resultados

## Resultados do Projeto

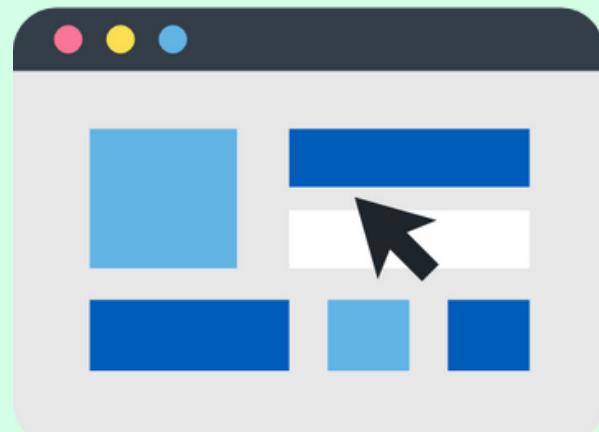
### Comparação dos Modelos

Modelos	Versão 1	Versão 2 (sem Pulgão verde dos cereais)
precisão	84.8%	93.1%
mAP	80.3%	91.1%
recall	75.4%	84.5%

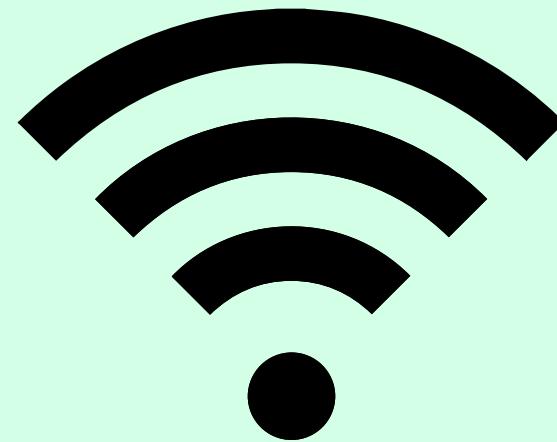
- Segunda versão do modelo se mostrou melhor do que a primeira versão
- Sistema de e-mail mostrou eficiência em compartilhar informações com o usuário
- Mesmo realizando tudo pelo terminal da máquina, é muito útil

# Conclusão

## Pontos a serem aprimorados



**Criação de  
interfaces gráficas**



**Rodar localmente**



**Novas imagens de  
alta qualidade**



**Teste em lavoura  
real**

# Referências Bibliográficas

## **Deep learning applied to plant pathology: the problem of data representativeness. Tropical Plant Pathology**

Barbedo, J. G. A. (2022) Deep learning applied to plant pathology: the problem of data representativeness. *Tropical Plant Pathology*, v. 47, p. 85-94.

## **Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. Computers and Electronics in Agriculture**

Barbedo, J. G. A. (2018) Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. *Computers and Electronics in Agriculture*, v. 153, p. 46-53.

## **InsectCV: A system for insect detection in the lab from trap images, Ecological Informatics**

Cesaro Júnior, T.; Rieder, F.; Di Domênico, J. R., Lau, D. (2022) InsectCV: A system for insect detection in the lab from trap images, *Ecological Informatics*, v. 67, 101516.<https://doi.org/10.1016/j.ecoinf.2021.101516>

## **Agricultura de precisão: o que é e por que tem sido tão importante para a produção de alimentos. Exame Agro**

Exame Solutions (2024) Agricultura de precisão: o que é e por que tem sido tão importante para a produção de alimentos. Exame Agro. Disponível em: <https://exame.com/agro/agricultura-de-precisao-o-que-e-e-por-que-tem-sido-tao-importante-para-a-producao-de-alimentos/>. Acesso em: 30 set. 2024.

## **Deep learning models for plant disease detection and diagnosis. Computers and Electronics in Agriculture**

Ferentinos, K. P. (2018) Deep learning models for plant disease detection and diagnosis. *Computers and Electronics in Agriculture*, V. 145, P. 311-318.

## **Deep learning models for plant disease detection and diagnosis. Computers and Electronics in Agriculture**

Ferentinos, K. P. (2018) Deep learning models for plant disease detection and diagnosis. *Computers and Electronics in Agriculture*, V. 145, P. 311-318.

# Referências Bibliográficas

## A method for counting and classifying aphids using computer vision. Computers and Electronics in Agriculture

Lins, E. A.; Rodriguez, J. P. M.; Scoloski, S. I.; Pivato, J.; Lima, M. B.; Fernandes, J. M. C.; Pereira, P. R. V. S.; Lau, D.; Rieder, R. (2020) A method for counting and classifying aphids using computer vision. Computers and Electronics in Agriculture, v. 169, p. 105200. <https://doi.org/10.1016/j.compag.2019.105200>.

## Using deep learning for image-based plant disease detection. Frontiers in Plant Science

Mohanty, S. P.; Hughes, D. P.; Salathé, M. (2016) Using deep learning for image-based plant disease detection. Frontiers in Plant Science, v. 7, article 1419.

## Modelos de aprendizagem de máquina para predição da presença de desoxinivalenol em grãos de trigo por meio de análises multiespectrais. Congresso Brasileiro de Agroinformática (SBIAGRO)

Zanini, E.; Zaions, D. F.; Zanatta, A. L.; Hölbiger, C. A.; Pavan, W. (2021) Modelos de aprendizagem de máquina para predição da presença de desoxinivalenol em grãos de trigo por meio de análises multiespectrais. Congresso Brasileiro de Agroinformática (SBIAGRO), Porto Alegre: Sociedade Brasileira de Computação, p. 207-214. <https://doi.org/10.5753/sbiagro.2021.18392>.

## Pulgão no Trigo: ocorrência, danos, monitoramento e controle

NNO, P. Pulgão no Trigo: ocorrência, danos, monitoramento e controle. Disponível em: <https://news.osalim.com.br/agronegocio/pulgao-no-trigo-ocorrencia-danos-monitoramento-e-controle?uid=124420>.

A close-up photograph of rice plants in a field. The plants are tall and green, with long, thin leaves and small clusters of rice grains at the top. Water droplets are visible on the leaves and stems, reflecting light. The background is slightly blurred, showing more of the field.

Obrigado pela Atenção